

Preoperative Hypertension: Surgical Risk Analysis using VitalDB CASE Database

모바일시스템공학과 32240410 김나경
모바일시스템공학과 32244367 주예나

Contents

- 0. Introduction
- 1. Overall Exploratory Data Analysis
- 2. Hypertension-Focused EDA
- 3. Single-Feature-Focused Regression Analysis
- 4. Hypertension Prediction Model
- 5. Clustering & UMAP & Cluster SHAP
- 6. Conclusion
- 7. Expansion Strategy

0. Introduction

프로젝트 배경

문제의식 형성

모바일 ECG 프로젝트를 통해 건강 지표가
다양한 요인에 의해 달라진다는 사실 체감
→ 병원에서도 단순 feature만으로 특정 질환 여부 판단이 어렵다는 문제 인식

연구 아이디어

VitalDB에는 고혈압과 관련된 임상·수술·환자 정보가 대규모로 존재
→ 이 복합 정보를 이용하면 데이터 기반 고혈압 탐지가 가능할 것이라는
가설 수립

연구 필요성

간접적으로 환자의 고혈압 여부를 측정할 수 있는 요소를 발견한다면
고도화된 데이터 없이도 단순 검진 결과를 통해
환자의 질환 예측 모델을 수립 가능

연구 목표

VitalDB 데이터를 활용해
수술 전 고혈압을 탐지하고,
어떤 perioperative 특징이
고혈압과 연관되는지를
규명하는 것.

About Dataset

1. VitalDB란?

서울아산병원에서 구축한 세계 최대 규모의 수술 중 생체신호(Open ICU/OR) 데이터베이스.
실제 수술실에서 수집된
ECG, 혈압(ABP), 산소포화도(SPO2), 호기말 CO₂, 마취기록 등
다양한 고해상도 실시간 시계열 데이터를 제공.
의료 AI 연구(예측모델·리스크 분석·생체신호 모델링)에 널리 사용되는 공개(Open Access) 데이터셋.

2. VitalDB에서 제공하는 데이터 형태

- 시계열 데이터 (Time-series)
- ECG, ABP 등 초당 수백 Hz 단위의 연속 신호
- 케이스 단위 데이터 (Tabular)
- **환자 특성, 수술 정보, 검사 결과 등 정적 정보**

⇒ 이 중에 본 프로젝트에서 사용한 것이 **cases.csv**

3. cases.csv:

VitalDB 전체 데이터의 기준이 되는 마스터 테이블
1줄 = 1명의 환자 / 1회의 수술
시계열 데이터와 매칭되는 케이스 ID 제공
환자 기본 특성·수술 정보·수술 전 검사·질병 정보 등
정적 요약 정보 포함
⇒ 모든 EDA와 모델링의 출발점이 되는 데이터
Shape: (6388, 74)

사용 데이터: cases.csv _ column 구성

기본 정보 & 수술 에피소드 정보

케이스/환자 식별

caseid, subjectid

케이스·수술 시간

casestart, caseend
anestart, aneend
opstart, opend

입퇴원 & 중환자실

adm, dis
icu_days, death_inhosp

환자 특성 & 수술 전 상태

기본 인구학 정보

age, sex, height, weight, bmi

전신 상태 / 응급 여부

asa (마취 전 전신상태 분류)
emop (응급 수술 여부)

수술 관련 특성

department (진료과)
optype (수술 유형)
dx (진단)
opname (수술 이름)
approach (수술 접근법: open, laparoscopy 등)
position (수술 체위)
ane_type (마취 타입)

주요 기저질환 / 검사 여부

preop_htn (고혈압)
preop_dm (당뇨)
preop_ecg (심전도 검사 여부/결과)
preop_pft (폐기능 검사 여부/결과)

환자 특성 & 수술 전 상태

혈액학 / 응고

preop_hb (헤모글로빈)
preop_plt (혈소판)
preop_pt, preop_aptt (응고 시간)

전해질 & 대사

preop_na, preop_k (Na, K)
preop_gluc (혈당)
preop_alb (알부민)
preop_ast, preop_alt (간 기능)
preop_bun, preop_cr (신장 기능)

혈액 가스 / 산염기 균형

preop_ph
preop_hco3
preop_be

preop_pao2, preop_paco2, preop_sao2

Data Preprocessing

1. 성인 필터링

```
df = df[df["age"] >= 18]
```

소아/청소년 케이스 제거
성인 수술만 분석하기 위한 기본 필터

2. 타겟 결측 제거

```
df = df[~df["preop_htn"].isna()]
```

고혈압 여부(preop_htn)가 없는 행 제거
타겟이 없는 데이터는 모델링 불가 → 반드시 제외

3. 수치형 변수 결측값 → 중앙값(Median)으로 대체

```
for col in num_cols:  
    df[col] = df[col].fillna(df[col].median())
```

labs(혈색소, 혈소판, 전해질 등)과 같은 continuous 변수의 NaN 처리
왜도(skewness)가 있는 의료 데이터에 적합한 방식
이상치(outlier)에 강하고 데이터 분포 왜곡을 줄임


4. 범주형 변수 ONE-HOT 인코딩 (암묵적 결측 처리 포함)

- sex, department, optype, asa 등 범주형을 더미 변수로 변환
- NaN이 있을 경우 → 해당 더미들이 모두 0이 되어 자동으로 결측 표현됨
→ 별도 결측치 처리 필요 없음
- Boolean 컬럼은 1/0으로 변환해 Logistic Regression에서 사용 가능하게 만듦

5. Feature 정리 및 불필요한 컬럼 제외

- caseid, opname처럼 모델에 필요 없는 컬럼 제거
- age, BMI, ASA, labs, department, optype 등 중요한 feature 유지
- boolean → int 변환

Pipeline



Hypothesis

가설 1 — 변수 간의 잠재적 연관성

나이, BMI, ASA와 같은 기본 임상 변수들은 고혈압 여부와 일정한 관련성을 가질 수 있다.

가설 2 — 변수 간 상호작용 가능성

특정 변수(고혈압에 영향을 주는 기본 임상 변수) 사이에는 구조적 관계 또는 간접적인 연결고리가 존재할 가능성이 있다.

가설 3 — 위험 환자군의 잠재적 분류 가능성

고혈압 환자군은 서로 다른 특성을 가진 여러 하위 그룹으로 구성되어 있을 수 있다.

1. Overall Exploratory Data Analysis

Cohort Overview:

Patient Demographics & Preoperative Status

N = 6,388 surgical cases



성별: 남성 50.8% / 여성 49.2%

동반질환: 당뇨 10.3%, 고혈압 30.8%

평균 연령: $\approx$ 57세

BMI: 평균 23.3, 비만율 4.1%


응급수술: 4% (emop=1)



Age Distribution and Clinical Implication

주 연령대는 40-80세가 80% 이상

일부 고령군(80+) 포함
→ 기본 위험 수준 높음




BMI Characteristics

평균 BMI: 23.3 (정상)

75%가 BMI < 25


비만률(BMI $\geq$ 30)은 4.1%로 일반 인구 대비 ↓



BMI Stats	
count	6388.000000
mean	23.278522
std	3.623655
min	11.300000
25%	20.900000
50%	23.100000
75%	25.400000
max	43.200000
obesity($\geq$ 30%)	4.085786

→ BMI 분포는 정상 범위 중심이며, 비만에 의한 부정맥 위험은 제한적

Preoperative Risk Stratification: ASA Classification




ASA는 수술 전 환자의 전반적인 건강상태를
1~6의 숫자로 표시한 지표

숫자가 높을수록 건강상태가 좋지 않아
수술 위험이 커진다는 뜻

ASA 2가 가장 많음 (약 58%)

고위험군($ASA \geq 3$): 약 12%

Age-ASA Relationship: Older Patients → Higher Risk



고령일수록 ASA 등급이 상승하는 패턴

80세 이상 연령군의 ASA 3 이상 비율 약 26%

연령과 ASA 등급의 상관관계수: $\rho = 0.28$

→ 연령이 증가할수록 ASA 등급이 상승



asa	1.0	2.0	3.0	4.0	6.0
age_group					
<40	50.467290	35.981308	10.981308	1.518692	1.051402
40-60	36.494926	54.410617	8.743169	0.351288	0.000000
60-80	15.743551	70.485584	12.822458	0.796662	0.151745
80+	4.975124	69.154229	23.383085	2.487562	0.000000

Surgery Duration

1시간 미만 수술이 가장 많고, 시간이 길어질수록 건수가 꾸준히 줄어드는 우하향 형태


ASA 1~4 순서대로 중앙값 지속 상승

ASA 4 중앙값이 가장 높음



→ 수술시간은 ASA에 따라 증가 (ASA=6 제외)

Mortality by Age Group




death_inhosp	0	1
age_group		
<40	868	12
40-60	2599	16
60-80	2661	24
80+	203	5

death_inhosp → 0 = Alive, 1 = Death

전체 사망은 1% 미만의 드문 이벤트

나이가 많아질수록 사망 비율이 조금씩 증가

Mortality by ASA



ASA가 높을수록 사망 비중 상승

death_inhosp	0	1
asa		
1.0	1783	9
2.0	3682	17
3.0	686	17
4.0	36	12
6.0	13	0

death_inhosp → 0 = Alive, 1 = Death


ASA 4는 사망률 25%로
전체에서 극소수지만 위험도 확연히 높음

Mortality by Emergency Surgery

응급 환자의 사망률: 3.7%
비응급 환자의 사망률: 0.5%

비응급 대비 약 7.4배 높음

절대 건수는 응급 29명,
비응급 28명으로 희귀 이벤트 특징




death_inhosp	emop	
	0	1
0	5578	28
1	753	29

death_inhosp → 0 = Alive, 1 = Death

Comorbidity Burden

수술 전 당뇨: 10.3%

수술 전 고혈압: 30.8%



→ 약 30%가 고혈압, 10%가 당뇨로, 만성질환이 상당 비율 포함

⇒ 고혈압 분석에 VitalDB 데이터셋을 활용한 주된 이유

Preoperative Lab Profile

	preop_hb	preop_k	preop_na
count	6047.00000	5767.00000	5765.00000
mean	12.83319	4.196411	140.026366
std	1.98949	0.408209	2.895233
min	3.50000	2.50000	111.00000
25%	11.60000	3.90000	139.00000
50%	13.00000	4.20000	140.00000
75%	14.20000	4.40000	142.00000
max	20.20000	8.40000	150.00000

헤모글로빈(Hb) 평균 12.8, 빈혈(Hb<12) 28%


칼륨(K) 평균 4.1
K abnormal(저/고칼륨혈증) 4.7%

나트륨(Na) 평균 140, 일부 과다/부족 존재

고혈압 영향 가능성

→ 수술 전 검사에서 일부 이상 수치가 관찰
⇒ 추후 고혈압과의 관계 규명

Correlation Summary: Patient Feature Relationships



연령-ASA: $\rho = 0.28 \rightarrow$ 고령일수록 위험도 상승

ASA & 연령 vs 사망률:
약한 양의 상관 $\rightarrow$ 희귀 이벤트 특성

BMI, 수술 전 검사 수치 vs 주요 위험 지표:
상관 거의 없음 $\rightarrow$ 교란 적음

emop vs 사망률: heatmap에는 약하게
보이지만 cross-table에서 강하게 확인됨

$\rightarrow$ 환자 위험도 결정의 핵심 축은 연령·ASA·응급수술

Key Findings

Cohort는 고령 환자 중심 + 고위험군 적절히 포함

BMI 정상 중심 → 비만 비율 작음

ASA·동반질환·수술 전 혈액검사 이상치 모두 실질적 위험요인 포함

응급수술군은 사망률 7.4배↑ → 위험도 높은 환자군

ASA 상승 & 고령 → 사망률 상승

2. Hypertension-Focused EDA

고혈압 위험도 분석에 사용한 변수 요약

케이스 기본 정보 (수술 Episode 정보)

고혈압 위험도와 시간적 맥락을 연결할 때 필요한 기본 단위

- caseid — 케이스 ID
- subjectid — 환자 ID

케이스 기본 정보 (수술 Episode 정보)

고혈압 발생 시점·맥락을 분석하기 위한 시간 정보

- casestart, caseend — 전체 케이스 시간
- anestart, aneend — 마취 시작·종료
- opstart, opend — 수술 시작·종료

입원 중 중증도 지표

고혈압과 관련된 post-op 상태의 예후 평가 용도

- icu_days — ICU 재원일수
- death_inhosp — 입원 중 사망 여부

케이스 기본 정보 (수술 Episode 정보)

고혈압 위험도와 시간적 맥락을 연결할 때 필요한 기본 단위

- caseid — 케이스 ID
- subjectid — 환자 ID

선택한 컬럼 수: 30

전신 상태 및 수술 특성

고혈압 위험의 confounders로 반드시 포함해야 하는 요소

- asa — ASA physical status (전신상태 등급)
- emop — 응급 수술 여부
- department — 진료과
- optype — 수술 유형
- opname — 수술 이름

주요 기저질환 및 심장 관련 검사

고혈압과 직접적으로 연결되는 Pre-op 상태

- preop_htn — 기존 고혈압 여부
- preop_dm — 당뇨 여부
- preop_ecg — 수술 전 ECG 검사 여부/결과

수술 전 혈액 및 전해질 검사 (Preoperative Labs)

고혈압 위험과 생리학적으로 연관된 핵심 변수
혈액/응고


- preop_hb — 헤모글로빈
- preop_plt — 혈소판
- preop_pt — PT
- preop_aptt — aPTT

전해질/대사

- preop_na — Sodium
- preop_k — Potassium
- preop_gluc — Glucose

기본 필터링 + 타겟(고혈압) 확인

- 성인(18세 이상)만 사용 + 고혈압 정보 있는 케이스만 사용
- 필터링 전: 6388건 → 필터링 후: 6331건



preop_htn

0 68.978045

1 31.021955

연속형 변수

: ['age', 'bmi', 'preop_hb', 'preop_plt', 'preop_pt', 'preop_aptt', 'preop_na', 'preop_k', 'preop_gluc', 'op_duration_min', 'ane_duration_min']


범주형 변수

: ['sex', 'department', 'optype', 'asa', 'emop', 'preop_dm']

- 연속형 변수 결측값은 중앙값으로 대체

고혈압 유무에 따른 기본 통계 - 연속형

연령대 비교




preop_htn		0	1
age	count	4367.000000	1.964000e+03
	mean	54.303183	6.533096e+01
	std	14.298568	1.113953e+01
	min	18.000000	2.200000e+01
	25%	45.000000	5.800000e+01
	50%	56.000000	6.600000e+01
	75%	64.000000	7.400000e+01
	max	94.000000	9.100000e+01

⇒ 고혈압 환자의 평균 연령이 유의미하게 높음

다음 변수들은 모두 그룹 간 분포가 거의 동일하게 나타남 ⇒ BMI (체질량지수), Na/K(전해질), Hb(헤모글로빈), 수술시간27

고혈압 유무에 따른 기본 통계 - 범주형

ASA (전신상태 등급) 비교




HTN=0(정상군)은 ASA 1-2가 대부분

HTN=1(고혈압군)은

- ASA 2 비중 증가
- ASA 3 비중이 정상군보다 명확히 높음

고혈압 환자는 동반질환이 많아 전신상태(ASA)가 더 나쁜 경향

당뇨 여부 비교



정상군: 대부분 DM=0

HTN군: DM=1 비율이 상대적으로 크게 증가
고혈압 ↔ 당뇨 동반질환 가능성 시사

통계 검정 (Mann-Whitney & Chi-square)

◆ Mann-Whitney U Test (Numeric Variables)

정규성을 가정하지 않고 두 그룹의 분포 차이를 비교하는 비모수 검정이다.
중앙값·분포 형태가 다를 때 유의한 차이로 나타난다.

▪ 해석 방법

$p < 0.05 \rightarrow$ 두 그룹의 분포가 유의하게 다름
단, 대규모 데이터에서는 아주 작은 차이도 p-value가 0(유의)
반드시 실제 차이(효과 크기)와 그래프를 함께 해석해야 함

Age | p=value = 0.0000

⇒ 고혈압과 연령은 강한 연관

◆ Chi-Square Test (Categorical Variables)

범주형 변수의 빈도 분포가 두 그룹에서 동일한지를 검정하는 방법이다.
기대 빈도와 관찰 빈도의 차이를 기반으로 계산된다.

▪ 해석 방법

$p < 0.05$

ASA | p=value = 0.0000

⇒ 고혈압 환자는 동반질환이 많아 ASA 높아지는 패턴

p-value | p=value = 0.0000

⇒ 고혈압과 당뇨는 동반질환

Statsmodels Logistic Regression

1) 분석 목적

preop_htn (0=정상, 1=고혈압)을 종속변수로 설정

고혈압과 연관된 독립적 요인(독립 예측 변수)을 파악하기 위해 로지스틱 회귀(Logistic Regression) 수행

2) 데이터 전처리 과정

(a) 연속형 변수 & 범주형 변수 분리

num_cols, cat_cols 리스트를 기반으로 변수 분류

(b) One-hot encoding

범주형 변수는 dummy 변수 생성

drop_first=True로 baseline 제거하여 다중공선성 방지

(c) Boolean → int 변환

(d) 결측치 제거

(e) y, X 분리

y = preop_htn

X = independent vars


(f) 상수항 추가

sm.add_constant()

3) 모델 적합

- Statsmodels의 Logit()으로 로지스틱 회귀 수행
- 회귀계수(coef) → log-odds
- Odds ratio(=exp(coef))로 해석 용이하게 변환

Statsmodels Logistic Regression



변수	OR	해석
ASA 3.0	12.6	ASA 3 환자는 ASA 1 대비 약 12배 고혈압일 확률 증가
ASA 4.0	9.0	약 9배 증가
ASA 2.0	7.0	약 7배 증가
Transplantation (이식 수술)	2.34	이식 수술 환자는 고혈압 Odds가 2.3배 증가
Vascular (혈관 수술)	1.42	혈관 수술도 연관 ↑
preop_dm_1	1.23	당뇨 환자는 고혈압일 확률이 23% 증가
age	1.06	나이가 1세 증가할 때마다 고혈압 Odds가 6% 증가

Key Findings

시각화 기반 기초 탐색 결과

1. 나이
2. ASA (전신상태 등급)
3. preop_dm (수술 전 당뇨)

통계 검정

1. 나이 ($p < 0.0001$)
2. ASA (전신상태 등급) ($p < 0.0001$)
3. preop_dm (수술 전 당뇨) ($p < 0.0001$)

로지스틱 회귀 분석

1. ASA (전신상태 등급)
ASA 3: OR 12.6
ASA 4: OR 9.0
ASA 2: OR 7.0
2. 수술 종류
이식 수술 OR 2.34
혈관 수술 OR 1.42
3. preop_dm (수술 전 당뇨) OR 1.23
4. 나이: OR 1.06

⇒ 나이 / ASA / 당뇨가 고혈압에 영향을 주는 주요 feature로 확인됨


3. Single-Feature-Focused Regression Analysis

ASA vs HTN

OR plot


$$\text{Logit(HTN)} = \beta_0 + \beta_1 \cdot \text{C(ASA)} + \beta_2 \cdot \text{age} + \beta_3 \cdot \text{BMI} + \varepsilon$$

Adjusted OR of HTN by ASA class (adjusted for age, BMI)



Age subgroup plot (<60 vs ≥60)

HTN proportion by ASA class and age group



**ASA 등급이 높아질수록 고혈압 위험이 증가하며,
age·BMI를 조정해도 이 관계는 유지된다.**

Preoperative metabolic labs vs HTN

단변량 분석 결과 (Mann-Whitney)

Lab	HTN 환자 변화 방향	p-value
Hb	↓ 낮음	1.4e-06
Platelet	↓ 약간 낮음	0.0058
PT	↑ 높음	4.6e-18
aPTT	약간 ↑	1e-08
Glucose	↑ 높음	3.3e-38

→ 단변량만 보면 모든 lab이 HTN과 관련 있어 보인다.

- Hb 감소 (빈혈)

→ 고혈압 환자는 Hb가 낮은 경향이 있으며, 심혈관 기능 저하·만성 질환 동반 가능성을 시사.

- PT 증가 (응고 시간 지연)

→ 고혈압 환자에서 응고/출혈 시스템의 변화 가능성 존재.

- Glucose 증가 (혈당 상승)

→ 대사증후군·인슐린 저항성과 연결되는 패턴.

다변량 로지스틱 회귀 결과 (age, BMI 조정 후)

회귀식

$$\text{Logit(HTN)} = \beta_0 + \beta_1 \cdot \text{age} + \beta_2 \cdot \text{BMI} + \beta_3 z_{\text{Hb}} + \beta_4 z_{\text{Platelet}} + \beta_5 z_{\text{PT}} + \beta_6 z_{\text{aPTT}} + \beta_7 z_{\text{Glucose}}$$

변수	Coef	OR	p-value	의미
Hb	-0.1759	0.84	<0.001	Hb 낮을수록 HTN ↑
Platelet	0.0338	1.03	0.27	연관성 X
PT (응고 시간)	0.1903	1.21	<0.001	PT 길수록 HTN ↑
aPTT	0.0368	1.04	0.22	연관성 X
Glucose	0.1199	1.13	<0.001	혈당 높을수록 HTN ↑

Surgery duration vs HTN

group	mean(min)
HTN=0	131.9
HTN=1	143.7

HTN 그룹(고혈압군)이
평균적으로 수술시간이 더 길다

Mann-Whitney U test: Surgery durations

op_duration_min (수술 시간)	p-value = 2.953e-07
ane_duration_min (마취 시간)	p-value = 1.064e-07

→ 고혈압 환자의 수술·마취 시간이 통계적으로 유의하게 더 길다.

Surgery duration vs HTN

모델 1: age + BMI + z_op_duration_min + z_ane_duration_min

- age $\rightarrow p < 0.000$ (강한 양의 관계)
- BMI $\rightarrow p < 0.000$ (강한 양의 관계)
- z_op_duration_min $\rightarrow p = 0.000$ (유의미한 양의 관계)
 $\rightarrow$ 수술 시간이 길수록 HTN일 odds가 상승
- z_ane_duration_min $\rightarrow p = 0.971$ (유의미하지 않음)

모델 2: age + BMI + z_ane (마취 단독)

z_ane $\rightarrow p = 0.000$ (유의미)
(마취 시간도 결국 HTN과 양의 관계를 가짐)

$\Rightarrow$ HTN 그룹은 Non-HTN 그룹 대비 수술·마취 시간이 유의하게 길다.

HTN vs ICU(중환자실) 이용

HTN=0	평균: 0.41일
HTN=1	평균: 0.62일

Mann-Whitney U test

: $p \approx 1.2 \times 10^{-11}$ (유의)

ICU 입실률

HTN=0	16.1%
HTN=1	23.5%


Chi-square test

: $\chi^2 \approx 46.9$, $p \approx 7.6 \times 10^{-12} \rightarrow$ 유의미

HTN vs 사망률

HTN=0	0.75%
HTN=1	0.93%

$\chi^2 = 0.33$, $p \approx 0.56 \rightarrow$ 유의하지 않음



Key Findings

1. ASA $\propto$ **HTN**

2. 1/Hb(빈혈) $\propto$ PT $\propto$ Glucose $\propto$ **HTN**

3. 수술·마취 시간 $\propto$ **HTN**

3. ICU 이용(입실/재원일수) $\propto$ **HTN**

4. Hypertension Prediction Model



Preoperative HTN Prediction Mode

Logistic Regression

X: Numeric features: ['age', 'bmi', 'asa', 'preop_hb', 'preop_plt', 'preop_pt', 'preop_aptt', 'preop_na', 'preop_k', 'preop_gluc']
Categorical features: ['sex', 'department', 'optype', 'emop', 'preop_dm']
Y: 0 (고혈압 X), 1 (고혈압 O)


X shape: (6331, 15)
y distribution:
preop_htn
0 0.68978
1 0.31022

Classification Report



- HTN Recall = 0.761
- HTN Precision = 0.519
- Macro F1 = 0.690
- Accuracy = 0.707
- **Test ROC-AUC = 0.803**
- **5-fold CV mean AUC = 0.803 ± 0.014**

Feature Importance (Odds Ratio 기반)



해석
나이 많을수록 HTN 위험 증가
고위험 ASA 환자일수록 HTN 동반 가능성 높음
비만 → HTN 위험 요인
원래 고위험 환자군에 HTN 비율 높음
HTN 환자가 많이 포함되는 수술과
응고지표(PT)가 미세하게 증가한 환자군에서 HTN 경향
고난도 수술군에서 HTN 많이 동반됨
아주 약한 양의 관련성

HTN 예측 모델은 결국 “연령 + 비만 + ASA 위험도 + 이식 수술군”이 주요 영향 인자이며, 이는 우리가 앞서 EDA 및 회귀 분석에서 얻은 결론과 완벽하게 일치한다.

여러 고혈압 예측 모델 비교

model	auc_mean	auc_std
GradientBoosting	0.811702	0.007144
RandomForest	0.806071	0.009761
SVM_RBF	0.803198	0.009458
LogReg	0.800041	0.007865

⇒ Best Model = GradientBoosting

GradientBoosting


classification report

	precision	recall	f1-score	support
0	0.796	0.835	0.815	874
1	0.589	0.524	0.555	393
accuracy			0.739	1267
macro avg	0.692	0.680	0.685	1267
weighted avg	0.732	0.739	0.734	1267


Test ROC-AUC: 0.8118009095090863

GradientBoosting

Confusion Matrix - GradientBoosting




ROC curve comparison: Best vs Logistic Regression




GradientBoosting _ 예측 기여도 분석

1. 전처리 후 최종 feature 이름 추출
(Scaling된 수치형 + OneHot된 범주형)
2. GradientBoosting 모델 객체 로딩
(best_pipe.named_steps["clf"])
3. feature_importances_ 가져오기
(GB의 정보 이득 기반 변수 중요도)
4. DataFrame으로 정리 후 상위 변수 확인
5. Top 10 Feature Importance 그래프 시각화



⇒ ASA, 연령, BMI가 1-3위

GradientBoosting_SHAP 분석



ASA 값이 높을수록(핑크) → SHAP > 0 (HTN 예측↑)

ASA 값이 낮을수록(블루) → SHAP < 0 (HTN 예측↓)

⇒ 고혈압은 전신 상태가 나쁜 환자군에서 흔히 나타난다

⇒ 나이가 많을수록(핑크) HTN 예측에 양의 영향


⇒ BMI 높음(핑크) → HTN 예측↑

- HTN은 전신 상태(ASA), 연령, 비만이 핵심적인 위험 요인

- 임상적 직관과 완벽히 일치하는 모델 결과


GradientBoosting _ SHAP 분석_feature 상호작용

ASA·Age에 따른 HTN 위험도 영향 (SHAP 분석)



- ASA가 증가하는 환자에 따라 SHAP 중요도가 증가하지만 age의 증가와는 크게 관련 없음


Age·ASA에 따른 HTN 위험도 영향 (SHAP 분석)



- Age는 선형적으로 HTN 위험을 증가시키며 특히 ASA가 높은 환자에서 영향이 더 크다
⇒ Age와 ASA는 **부분적 상호작용**이 존재한다.


GradientBoosting _ SHAP 분석_feature 상호작용

BMI·Age에 따른 HTN 위험도 영향 (SHAP 분석)



- BMI가 증가할수록 HTN 예측 기여도가 선형적으로 증가
- BMI와 Age 간의 **interaction** 효과는 거의 없음
_ BMI와 Age는 독립적으로 중요한 feature

Key Findings



5. Clustering & UMAP & Cluster SHAP

K-means 최적 클러스터 수 (k) 탐색 결과

⇒ 수술 전 생리학 기반으로 환자를 큰 패턴으로 나누기

Silhouette Score 결과

k	Silhouette Score
2	0.4676
3	0.2758
4	0.2967
5	0.2879
6	0.2848

클러스터별 고혈압 비율

Cluster	HTN 비율
Cluster 0	31%
Cluster 1	0%

k=2가 가장 높은 실루엣 점수

→ 가장 안정적이고 분리도 높은 클러스터링 구조

클러스터별 특징 요약 (주요 feature 평균)

cluster	0	1	diff_abs
preop_aptt 혈액 응고까지 걸리는 시간	32.645077	232.950	200.304923
preop_plt 혈소판 수치, 출혈관련 지표	241.595227	66.500	175.095227
preop_pt 혈액 응고능력	100.679627	26.250	74.429627
preop_gluc 수술 전 혈당	114.939940	151.750	36.810060
age	57.729730	49.000	8.729730
preop_hb 빈혈 여부 판단	12.865892	5.675	7.190892
bmi	23.320847	18.475	4.845847
asa	1.844792	3.250	1.405208
preop_dm 당뇨 여부	0.103841	1.000	0.896159
emop 응급 수술	0.119488	1.000	0.880512
preop_htn 고혈압 여부	0.310416	0.000	0.310416

Cluster 0 : 정상적인 preoperative profile을 가진 일반 환자군

- APTT, PT, PLT 정상 범위
- 혈색소(Hb)도 정상
- 연령대도 평균 57세
- BMI도 정상(23)
- HTN 동반도 약 31%
- 응급 수술 비율도 낮음

⇒ 일반적인 elective surgery 환자층

클러스터별 특징 요약 (주요 feature 평균)

cluster	0	1	diff_abs
preop_aptt 혈액 응고까지 걸리는 시간	32.645077	232.950	200.304923
preop_plt 혈소판 수치, 출혈관련 지표	241.595227	66.500	175.095227
preop_pt 혈액 응고능력	100.679627	26.250	74.429627
preop_gluc 수술 전 혈당	114.939940	151.750	36.810060
age	57.729730	49.000	8.729730
preop_hb 빈혈 여부 판단	12.865892	5.675	7.190892
bmi	23.320847	18.475	4.845847
asa	1.844792	3.250	1.405208
preop_dm 당뇨 여부	0.103841	1.000	0.896159
emop 응급 수술	0.119488	1.000	0.880512
preop_htn 고혈압 여부	0.310416	0.000	0.310416

Cluster 1 : 응급 + 출혈 + 중증 환자군 (rare extreme cluster)

- APTT: 232.9 (정상 26~36) → 거의 응고불능 수준
 - PLT: 66 (정상 150~450) → 심한 thrombocytopenia
 - PT: 26.25 (정상 10~14) → 응고장애
 - Hb 5.6 (정상 11~16) → 중증 빈혈
 - Glucose 150↑ → 스트레스/응급 상태 가능성
 - ASA 3.25 → 고위험 전신상태
 - preop_dm = 1.0 → 100% DM 있음
 - emop = 1.0 → 100% 응급수술
-
- HTN = 0 → 이 cluster는 아예 HTN 없음 (중증·응급 환자는 HTN 여부랑 무관)



⇒ 중증·출혈·응급 환자군이 자동 분류된 클러스터.
⇒ 즉, 높은 위험도의 acute patient cluster 형태.

Key Findings

Cluster	설명
Cluster 0 (일반 환자군)	정상 범위의 metabolic / coagulation profile / elective 수술 비율 높음 / HTN 약 31% 포함
Cluster 1 (응급·출혈·중증 환자군)	극단적으로 이상한 coagulation 값(APTT ↑, PT ↑, PLT ↓), Hb ↓, 고혈당, ASA 3+, 100% 응급수술, 100% DM

UMAP 기반 KMeans로 최적 k 찾기 ⇒ 환자들의 미세한 구조적 패턴(heterogeneity)까지 탐지

k	Silhouette	Inertia
2	0.5259	187450
3	0.6178	88631
4	0.5845	53343
5	0.6252	37572
6	0.6791	18412
7	0.6543	15472
8	0.6729	11003
9	0.6246	9078



Best k (UMAP 2D 기준) = 6

*Inertia: 클러스터에 속한 샘플이 얼마나 가깝게 모여 있는지를 나타냄

Cluster별 평균 값으로 분석

Cluster별 고혈압 평균 값

cluster	preop_htn average
0	0.000
1	0.323
2	0.992
3	0.000
4	0.0026
5	0.505

Cluster 0

“Healthy Elective Cluster (HTN 0%)”

preop_htn = 0.00 → 고혈압 없음

특징

- Age 49
- BMI 23.1
- ASA 1.00 (가장 낮음)
- Glucose 정상
- EMOP 0 → elective

해석

- 가장 건강한 elective 군집.
- 고령·ASA·BMI 모두 낮아 HTN이 존재하지 않음.
- 즉, HTN은 이 cluster와 무관한 risk factor.

Cluster 1

“Moderate HTN Cluster (HTN 32%)”

preop_htn = 0.323 → 전체의 1/3이 HTN

특징

- Age 56.3
- BMI 22.4
- ASA 2.12 (높음)
- EMOP 0.96
→ 거의 모두 응급으로 표기된 값

해석

- 중간 수준의 HTN prevalence 클러스터.
- **ASA가 높아서** HTN군과 일부 overlap.
→ 다만 응급 비율이 높아
HTN signature가 희석됨.

Cluster 2

“HTN Core Cluster (≈99% 고혈압)”

preop_htn = 0.992 → 거의 모두 HTN 환자

특징

- Age 가장 높음 (64.9)
- BMI 가장 높음 (24.33)
- ASA 높음 (2.11)
- EMOP 거의 없음 (0.0007)
- Glucose도 높음 → metabolic burden ↑

해석

- 고혈압 환자가 가장 집중된 전형적인
“만성질환형 Elective 환자군”
- **고령·고BMI·고ASA → HTN을 설명하는 핵심
프로필과 완벽히 일치함.**

Cluster 3

“Younger Elective Surgical Group (HTN 0%)”

preop_htn = 0.00

특징

- Age 54.6
- BMI 23.14
- ASA 1.69
- EMOP 0

해석

- 전형적인 elective general surgery 환자군.
- ASA/나이/BMI 분포가 HTN과 상관없음 → HTN 없음.

Cluster 4

“Low-HTN Surgical Cluster (~0%)”

preop_htn = 0.0026

특징

- Age 56.6
- BMI 22.87
- ASA 2.09
- Glucose 정상
- EMOP 거의 0

해석

- 연령과 ASA는 높은데도 HTN이 거의 없는 독특한 cluster.
- HTN이 아닌 다른 factor(수술 종류 등)가 클러스터링 구조를 지배함.

Cluster 5

“Mixed Chronic-Metabolic Group (HTN 50%)”

preop_htn = 0.505 → 절반이 HTN

특징

- Age: 64.6 → 고령
- BMI: 23.7
- ASA: 2.19 (높음)
- DM: 0.967 (거의 모두 당뇨)
- Glucose 아주 높음 (161.3 → 가장 높은 cluster)

해석

- HTN 절반 + DM 거의 100% → 전형적인 **만성 대사질환** 클러스터
HTN은 이 군집에서도 강하게 나타남.
- “Metabolic syndrome cluster (HTN + DM + Glucose↑)”에 가까움.


HTN이 집중된 클러스터

- Cluster 2 ($\approx 99\%$) $\rightarrow$ HTN core group
- Cluster 5 ($\approx 50\%$) $\rightarrow$ HTN + DM metabolic group
- Cluster 1 ($\approx 32\%$) $\rightarrow$ moderate-risk group

HTN이 존재하지 않는 클러스터

- Cluster 0 (0%) $\rightarrow$ healthiest elective group
- Cluster 3 (0%) $\rightarrow$ elective surgical group
- Cluster 4 ($\sim 0\%$) $\rightarrow$ older but non-HTN cluster

Cluster-wise SHAP Importance 해석 (Mean SHAP 기반)




⇒ ASA가 거의 모든 클러스터에서 가장 강력한 영향 요인

⇒ 나이(Age)도 모든 클러스터에서 꾸준히 높은 영향

⇒ BMI는 중간 정도의 영향 – 일부 클러스터에서는 강함

Cluster-wise SHAP Importance 해석 (정규화 기반)



각 피처가 각 클러스터 안에서 상대적으로 얼마나 중요한지

1) Cluster 1 (고 ASA·응급 특성)

- ASA, age의 상대적 중요도는 다소 낮음
→ 해당 클러스터는 모두 ASA가 높고 연령대가 높아, 차별적 설명력이 감소함
- 대신 응급 지표(emop), 수술 관련 피처(opt type)가 상대적으로 높은 설명력
→ HTN 예측에서 “환자 생리적 상태 vs 수술 맥락”의 비중이 다르게 작동함

2) Cluster 2 (고령 + 고 HTN 비율 그룹)

- age, BMI, ASA가 매우 높은 비중
- preop_gluc(혈당)이 상대적으로 높은 중요도를 보이는 첫 번째 군집
→ 대사질환 요소(고혈당)가 HTN과 함께 나타나는 전형적인 고위험군

3) Cluster 0, 3 (정상군 중심)

- ASA·age 영향력은 있으나, 다른 피처 대비 큰 차이는 없음
→ 저위험군에서는 다양한 피처들이 고르게 작용

4) Cluster 5 (DM·고혈당 특화 클러스터)

- preop_dm_1, preop_gluc 중요도가 유별나게 높음
→ HTN + DM 동반군으로 보이며
- “대사질환 조합형 고위험군”으로 해석 가능.

6. Conclusion

가설 증명

가설 1 — 변수 간의 잠재적 연관성

본 프로젝트의 회귀 분석 및 단일 변수 기반 탐색적 분석(EDA)을 통해
수술 전 기본 임상 변수(Age, BMI, ASA)가 고혈압 여부와 일정 수준의 관련성을 보일 가능성을 확인하였다.
이 분석 과정은 각 변수의 분포, 그룹 간 차이, 회귀 계수 등을 검토함으로써
가설 1의 타당성을 탐색적으로 평가하는 데 기여하였다.


가설 2 — 변수 간 상호작용 가능성

Age, ASA 등 주요 변수들 사이에 구조적인 연결 가능성을 확인하기 위해
상관 분석, 경로적 관계 구조 파악(예: Age-ASA 간 연결성 검토) 등을 수행하였다.
그 결과 특정 변수들이 단독 영향뿐 아니라 서로 연관된 형태로
고혈압과 관계를 형성할 수 있음을 탐색적으로 관찰할 수 있었으며,
이는 가설 2의 논리적 가능성을 지지하는 근거로 활용되었다.

가설 3 — 위험 환자군의 잠재적 분류 가능성

K-means 및 클러스터 기반 탐색을 통해 고혈압 환자들이
특정 특성 조합에 따라 여러 하위 그룹으로 나뉠 수 있는지 검토하였다.
클러스터별 특징을 비교·요약함으로써 환자군 내 이질성이 존재할 가능성을 확인하였고,
이는 가설 3에서 제시한 '위험 환자군의 잠재적 분류 가능성'을 탐색적으로 뒷받침하였다.

Hypertension Network: Predictors and Patient Clusters



전체 연구 종합 결론

본 연구는 VitalDB의 대규모 수술 전 데이터(cases.csv)를 기반으로, 고혈압(HTN)의 주요 예측인자들을 규명하고, 고혈압 환자 집단 내부의 잠재적 환자군을 탐색하는 것을 목표로 하였다. 분석 결과, ASA, Age, BMI의 세 축이 HTN 발생과 강하게 연관된 핵심 인자로 작용하였고, 이 세 인자를 중심으로 HTN과 주변 요인들이 연결되는 하나의 네트워크 구조가 도출되었다.

1) HTN의 주요 예측 인자: ASA·Age·BMI 중심의 삼각 구조

(1) ASA (전신상태 등급)

ASA 등급은 고혈압에 가장 직접적이고 영향력 있는 인자로 확인되었다. ASA가 높을수록 HTN 위험은 기하급수적으로 증가했는데, ASA 2·3·4에서 각각 OR이 7.0, 12.6, 9.0에 달하며 모델 전반에서 가장 중요한 feature로 일관되게 등장하였다. EDA에서도 고혈압 환자군에서 ASA 2·3 비중이 뚜렷하게 높았고, SHAP 결과 역시 ASA값 상승이 HTN 예측 확률을 크게 밀어올렸다.

(2) Age (나이)

나이는 ASA의 상승과 밀접하게 연결되어 있으며, ASA 상승이 다시 HTN 위험을 증가시키는 경로를 매개한다. 연령이 많을수록 고혈압 비율은 꾸준히 증가했으며, OR 분석에서도 Age는 $OR \approx 1.06$ 으로 유의한 양의 방향을 보였다. SHAP 분석에서도 Age 상승은 지속적으로 HTN 예측값을 높이는 패턴을 보였다.

(3) BMI (체질량지수)

BMI는 HTN의 독립적 위험인자로 확인되었다. 고혈압 환자군에서 BMI가 의미 있게 높았고, SHAP 결과에서도 BMI 증가 시 HTN 예측값이 상승하는 양상을 보였다. 고령·고BMI·고ASA의 조합은 매우 전형적인 고위험 만성질환 프로필을 형성한다.

2) HTN 연관 추가 요인: 대사·응고·수술 특성

ASA·Age·BMI라는 세 핵심 축 외에도, 다수의 검사값과 임상 특성이 HTN과 의미 있는 연관성을 보였다.

- 수술 전 대사·혈액검사: Hemoglobin↓, PT↑, Glucose↑
- 수술 시간·마취 시간: HTN 군에서 더 길게 나타남
- 수술 후 경과: ICU 이용 증가
- 동반질환: DM 보유 시 HTN odds 상승

이들은 단독으로 HTN을 결정하지는 않지만, HTN을 중심으로 주변에서 위험 신호를 강화하는 보조적 인자로 작용한다.

전체 연구 종합 결론

3) HTN 환자 내 잠재적 하위군(Cluster) 발견

UMAP과 K-Means 기반 클러스터링을 통해
고혈압 환자군 내부에도 서로 다른 특징을 가진 3개의 주요 고위험 환자군이 존재함을 확인하였다.

(1) 만성적 고위험 환자군 (고령·고BMI·고ASA)

- HTN 비율이 가장 높고
- 고령·비만·고ASA가 함께 나타나는 전형적인 만성 고혈압 프로파일
- SHAP에서 Age·BMI·ASA 모두 큰 영향
- 수술 시간도 길고 만성질환 패턴 강함

⇒ 전형적인 '만성 고혈압형' 환자군

(3) 대사·전신질환 중심 고위험군 (고령·고BMI·고ASA·DM 동반)

- Glucose↑, DM 비율↑, ASA↑
- 고령·고BMI·고ASA의 만성 패턴과 대사질환이 결합된 그룹
- HTN과 당뇨, 대사 이상이 구조적으로 묶여 있음

⇒ '고혈압+대사질환' 복합 위험군

(2) 급성 위험군 (출혈·응급 위기군)

- 고ASA + 응급수술 비중 매우 높음
- PT/APTT 등 응고 이상 심하고
- 100% 응급, 수술 시간과 중증도 상승
- HTN은 낮거나 거의 없음 → 고혈압보다 '급성 상태'가 위험도를 지배

⇒ 고혈압과 무관하게 급성·출혈성 위험이 중심인 환자군

전체 연구 종합 결론

종합 결론: HTN은 단일 현상이 아니라, 복합 위험 네트워크의 중심 노드

본 연구에서 HTN은 단순히 “혈압이 높은 상태”로 고립된 변수가 아니라, 나이·ASA·BMI·대사상태·응고상태·수술 특성을 잇는 네트워크 구조의 중심 노드로 나타났다.

- HTN을 예측하는 가장 강한 축은 ASA-Age-BMI
- HTN을 둘러싼 주변부에는 대사질환·수술 스트레스·응급상황 등의 위험 요인들이 자리함
- HTN 환자라고 해서 모두 동일한 위험군이 아니라 만성형/대사형/응급형으로 뚜렷한 아형이 존재

즉,
HTN은 여러 위험 요인이 교차하는 생리적·임상적 허브(hub)이며,
HTN 환자군 내부에도 서로 다른 임상적 정체성을 가진 하위군이 분명히 존재한다.

이러한 분석은
수술 전 환자 평가(Preoperative assessment)에서
고혈압 환자를 단일 집단으로 취급하는 기존의 관행을 넘어,
고혈압 환자군을 세분화하고 개별 리스크 기반으로 관리할 필요성을 강하게 시사한다.


7. Expansion Strategy

최소 변수 기반 고혈압 리스크 스크리닝 시스템

1. 활용 배경

- Feature Importance 및 SHAP 분석 결과, HTN 예측에 가장 큰 기여를 한 상위 3개 변수는 고도화된 수술 장비 데이터가 아닌 ASA, Age, BMI이므로 복잡한 데이터가 불필요
 - 수술 중 수집되는 ABP, ECG와 같은 시계열 데이터 없이 Static Data만으로도 AUC 약 0.81의 유의미한 예측 성능 달성
- ⇒ 수술실을 넘어 데이터 수집 환경이 열악한 1차 의료기관이나 일상 헬스케어 서비스로 확장 가능

2. 구체적인 활용 방안



사전 선별(Pre-Screening) 솔루션

1. 현황 및 문제점

기존에는 고혈압 진단을 위해 반복적인 혈압 측정과 의사의 문진이 필수적이었으며, 가면 고혈압(병원에서만 정상으로 나오는 경우) 환자를 놓치기 쉬움.

2. 활용 모델

Gradient Boosting 모델을 경량화하여 탑재

3. 적용 시나리오

1. 환자가 건강검진 문진표에 나이, 키, 몸무게, 기저질환(당뇨 유무)만 입력.

2. 시스템이 즉각적으로 '잠재적 고혈압 고위험군' 여부를 확률(%)로 제시.

3. 고위험군으로 분류된 환자에게만 혈액 정밀 검사를 권고하여 의료 자원 낭비 최소화.

모바일 헬스케어 앱을 통한 자가 리스크 관리

1. 개념

사용자의 입력 데이터에 기반한 '내 손안의 AI 진단 비서'

2. 구현 방식

사용자가 앱에 생년월일(Age)과 체중/신장(BMI)을 입력.

앱 내 간단한 설문을 통해 ASA 등급을 추정하는 프록시(Proxy) 변수 생성.

"귀하의 신체 정보를 분석한 결과, 고혈압 위험도는 상위 32%에 해당합니다"와 같은 예측 결과에 대한 직관적 피드백 제공.

3. 기대 효과

병원 방문이 어렵거나 꺼리는 숨겨진 환자군을 조기에 발굴하여 예방 관리 유도.

클러스터링 분석을 활용한 유형별 맞춤 처방 가이드

1. 단순 예측을 넘어선 개인화

본 연구의 K-Means/UMAP 클러스터링 결과를 적용하여, 환자를 단순한 고혈압 환자가 아닌 구체적인 **유형(Subtype)**으로 분류.

2. 유형별 맞춤 가이드 예시

Type A (Cluster 5 - 대사질환형): 고혈당과 비만이 동반된 유형

→ Action: "혈압 약 복용뿐만 아니라, 식단 조절을 통한 혈당 관리가 최우선입니다."

Type B (Cluster 2 - 노인성 만성형): 고령과 높은 ASA가 특징인 유형

→ Action: "무리한 운동보다는 낙상 방지 및 정기적인 심혈관 모니터링이 필요합니다."

Type C (Cluster 0, 3 - 저위험군): 현재 건강하나 예방이 필요한 유형

→ Action: "현재 상태 유지 및 연 1회 BMI 점검 권장."

감사합니다